

IUT Grand Ouest Normandie

Bachelor Universitaire de Technologie
Science des Données
Campus de Lisieux

Science des Données 1 - SAÉ 2.02
Estimation par sondage simple

Thématique

TP1 & TP2 - Statistique Inférentielle

Auteurs

MAULIDIA Nadira Aura
MBANG NDONG Glaineta

Table des matières

Introduction	3
1 TP1 - Exercice 1 : Création d'un jeu de données	4
1.1 Partie I : Population à deux modes	4
1.2 Partie II : Fonction generData2Mod	4
1.3 Partie III : Fonction generData3Mod	4
2 TP1 - Exercice 2 : Analyse de la distribution d'une variable quantitative	5
2.1 Indicateurs statistiques de ageEtudiantV1	5
2.2 Représentation graphique de ageEtudiantV1	5
2.3 Analyse de ageEtudiantV2	7
3 TP1 - Exercice 3 : Distribution de probabilité de l'estimateur	10
3.1 Fonction estimateurMoy	11
3.2 Influence de la taille d'échantillon sur la distribution de l'estimateur	11
3.3 Superposition des densités et conclusion	14
4 TP2 - Exercice 1 : Bootstrap de l'estimateur de la moyenne	15
4.1 Création de la population ageEtudiantV4	15
4.2 Fonction bootstrapEstimMoy	15
4.3 Simulation de 100 échantillons bootstrap	15
4.4 Représentation graphique de la distribution bootstrap	16
4.5 Intervalle de confiance bootstrap au niveau 95 %	16
Conclusion	17
Table des figures	18

Introduction

À travers ces deux travaux pratiques, nous cherchons à comprendre les mécanismes de l'estimation par sondage simple dans le cadre de la statistique inférentielle. Le contexte applicatif retenu est l'âge des étudiants inscrits en première année de Bachelor Universitaire de Technologie à l'IUT Grand Ouest Normandie.

Le premier TP (**TP1**) est structuré en trois exercices : la création de populations simulées comportant plusieurs modes à partir de distributions normales, l'analyse descriptive et graphique de ces populations, et enfin l'étude de la distribution de probabilité de l'estimateur de la moyenne pour différentes tailles d'échantillons.

Le second TP (**TP2**) porte sur la méthode du bootstrap, une technique de ré-échantillonnage permettant d'approcher la distribution d'un estimateur à partir d'un unique échantillon de données. Nous y construisons des intervalles de confiance bootstrapés pour la moyenne de l'âge des étudiants.

1 TP1 - Exercice 1 : Création d'un jeu de données

L'objectif de ce premier exercice est de créer, par simulation, des jeux de données présentant plusieurs modes principaux. Ces modes sont générés à partir de mélanges de distributions normales, ce qui permet d'obtenir des populations hétérogènes représentatives d'une réalité plus complexe.

1.1 Partie I : Population à deux modes

Dans un premier temps, nous créons une population de 200 individus constituée de deux sous-populations distinctes, stockées dans le vecteur popX. La première sous-population contient 165 individus tirés d'une loi normale de moyenne 20 et d'écart-type 1,2, tandis que la seconde regroupe 35 individus issus d'une loi normale de moyenne 27 et d'écart-type 1,8. Ce mélange de deux distributions normales produit une distribution bimodale, avec un premier pic centré autour de 20 ans (mode principal, représentant 82,5 % de la population) et un second pic autour de 27 ans (mode secondaire, 17,5 % de la population).

```
# Première sous-population de taille 165
x1 = rnorm(165, mean=20, sd=1.2)

# Deuxième sous-population de taille 35
x2 = rnorm(35, mean=27, sd=1.8)
```

Fig. 1. Code R de la population générée

1.2 Partie II : Fonction generData2Mod

Nous généralisons ensuite la démarche en créant la fonction generData2Mod, qui permet de simuler une population de taille arbitraire nbPop composée de deux modes définis par leurs proportions, moyennes et écarts-types respectifs. La contrainte $p + q = 100$ assure que les proportions s'additionnent à 100 %.

```
generData2Mod = function(nbPop, p, q, moyen1, ecart1, moyen2, ecart2) {
  population1 = rnorm(nbPop, moyen1, ecart1)
  population2 = rnorm(nbPop, moyen2, ecart2)

  grand_pop = (p/100*population1)+(q/100*population2)
  return(grand_pop)
}
```

Fig. 2. Code R de la création de la fonction generData2Mod

Nous testons cette fonction en créant la population ageEtudiantV1 de taille 1 400, dont 85 % des données proviennent d'une loi $N(20; 1,4)$ et 15 % d'une loi $N(23,2; 3,1)$. La moyenne obtenue est cohérente avec les paramètres choisis : elle se situe aux alentours de 20,48 ans, valeur proche de la moyenne théorique pondérée ($0,85 \times 20 + 0,15 \times 23,2 = 20,98$ ans). La légère différence est due au caractère aléatoire de la simulation.

```
ageEtudiantV1 = generData2Mod(1400, 85, 15, 20, 1.4, 23.2, 3.1)

print(mean(ageEtudiantV1))
```

Fig. 3. Code R de la génération de la population ageEtudiant

1.3 Partie III : Fonction generData3Mod

Nous étendons la logique précédente à trois modes en créant la fonction generData3Mod. Celle-ci suit le même principe que generData2Mod avec la contrainte supplémentaire $p + q + r = 100$. Nous l'utilisons pour créer ageEtudiantV2 : une population de 1 400 individus dont 70 % proviennent de $N(19; 0,8)$, 20 % de $N(22,5; 1,6)$ et 10 % de $N(25; 2,2)$

```
generData3Mod = function(nbPop, p, q, r, avg1, et1, avg2, et2, avg3, et3){
  population1 = rnorm(nbPop, avg1, et1)
  population2 = rnorm(nbPop, avg2, et2)
  population3 = rnorm(nbPop, avg3, et3)

  grand_pop = (p/100*population1)+(q/100*population2)+(r/100*population3)
  return(grand_pop)
}

ageEtudiantV2 = generData3Mod(1400, 70, 20, 10, 19, 0.8, 22.5, 1.6, 25, 2.2)

print(mean(ageEtudiantV2))
```

Fig. 4. Code R de la création de la fonction generData3Mod

2 TP1 - Exercice 2 : Analyse de la distribution d'une variable quantitative

À travers ce deuxième exercice, nous analysons la distribution des populations `ageEtudiantV1` et `ageEtudiantV2` à l'aide d'indicateurs statistiques et de représentations graphiques. Nous cherchons également à tester formellement la normalité des distributions.

2.1 Indicateurs statistiques de `ageEtudiantV1`

Nous utilisons la fonction `summary` pour obtenir les principaux indicateurs descriptifs de `ageEtudiantV1`. On remarque que la médiane (20,49 ans) est identique à la moyenne (20,49 ans), ce qui traduit une symétrie. Cependant, cette égalité n'implique pas nécessairement la normalité : la distribution `ageEtudiantV1` étant bimodale, cette coïncidence reflète plutôt l'effet de compensation entre les deux sous-populations, dont les modes se situent de part et d'autre de cette valeur centrale.

```
> summary(ageEtudiantV1)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
16.69  19.68   20.49   20.49  21.32   25.09
```

Fig. 5. Code R du résultat de la fonction `summary()`

2.2 Représentation graphique de `ageEtudiantV1`

Pour analyser la distribution de `ageEtudiantV1`, nous avons produit plusieurs représentations graphiques successives à l'aide des fonctions R `boxplot`, `hist` et `density`.

Le boxplot (Fig. 7) permet de visualiser la dispersion de l'ensemble de la population. On observe la présence de quelques valeurs extrêmes sur la partie droite de la distribution. La médiane se situe bien autour de 20 ans.

```
# Variable : ageEtudiantV1
boxplot(ageEtudiantV1,
        horizontal = TRUE,
        xlab = "Age",
        las = 1,
        col = "orchid",
        main = "Distribution de l'âge des étudiants inscrits en première année")
```

Fig. 6. Code R de la création du boxplot

Distribution de l'âge des étudiants inscrits en première année




Fig. 7. Distribution de l'âge des étudiants inscrits en première année pour `ageEtudiantV1`

L'histogramme (Fig. 9) confirme le caractère bimodal de la distribution : on distingue un pic dominant autour de 20 ans et un renflement secondaire aux alentours de 21 ans. Ce second mode est moins visible du fait de la faible proportion d'individus qui le compose (15 %). Le titre est mis en italique et coloré en bleu conformément aux exigences du TP.

```
hist(ageEtudiantV1,
     las = 1,
     ylim = c(0, 500),
     xlim = c(14, 26),
     col = "salmon",
     xlab = "Age",
     cex.axis = 1.2,
     cex.main = 1.5,
     main = expression(italic("Distribution de l'âge des étudiants inscrits en première année")), col.main = "blue")
```

Fig. 8. Code R de la création de l'histogramme




Fig. 9. Distribution de l'âge des étudiants inscrits en première année pour ageEtudiantV1

L'estimateur de densité non paramétrique à noyau gaussien (Fig. 11), obtenu via `density` et tracé avec `plot`, permet de visualiser plus clairement la forme de la distribution. La courbe met en évidence le double pic : un premier mode prononcé vers 20 ans et un second, moins marqué, vers 21 ans.

```
plot(density(ageEtudiantV1), lwd = 2,
     col = "black", main = "Histogramme lissé")
```

Fig. 10. Code R de la création de l'histogramme lissé




Fig. 11. Histogramme lissé

Nous avons testé la normalité de la distribution à l'aide de deux approches complémentaires.

D'une part, le QQ-plot (Fig. 13) obtenu avec la fonction `qqPlot` du package `car` révèle que les points s'écartent de la droite théorique dans les queues de distribution, ce qui suggère une déviation par rapport à la loi normale, notamment en raison du mode secondaire.

```
qqPlot(x = ageEtudiantV1)
```

Fig. 12. Code R de la création du QQ-plot de l'âge des étudiants inscrits en première année




Fig. 13. QQ-plot de l'âge des étudiants inscrits en première année

D'autre part, le test de Shapiro-Wilk, réalisé via la fonction `shapiro_test` du package `rstatix`, donne une p-value très supérieure à 0,05. La p-value obtenue (0,0707) est supérieure au seuil de 5 %, donc on ne rejette pas l'hypothèse H_0 de normalité. Ce résultat est à interpréter avec prudence : bien que le test ne détecte pas formellement de non-normalité ici, la population `ageEtudiantV1` a été construite comme un mélange de deux lois normales. Sa distribution est donc théoriquement bimodale, et la non-rejection de H_0 s'explique probablement par la proximité des deux modes (20 et 23,2 ans) et la faible proportion du second mode (15 %), qui rend la bimodalité difficile à détecter statistiquement sur cet échantillon.

```
> shapiro_test(ageEtudiantV1)
# A tibble: 1 x 3
  variable      statistic p.value
  <chr>         <dbl>     <dbl>
1 ageEtudiantV1    0.998  0.0707
> #Ainsi l'hypothèse Ho n'est pas rejetée
```

Fig. 14. QQ-plot de l'âge des étudiants inscrits en première année

2.3 Analyse de ageEtudiantV2

Nous répétons la même démarche pour `ageEtudiantV2`, la population à trois modes. La structure trimodale rend la distribution encore plus complexe. On retrouve trois zones de concentration : autour de 19,86 ans (mode dominant, 70 %), de 20,76 ans (20 %) et de 22,42 ans (10 %).

```
> summary(ageEtudiantV2)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
18.23  19.86   20.29   20.31  20.76   22.42
```

Fig. 15. Code R du résultat de la fonction `summary()`

```

boxplot(ageEtudiantV2,
        horizontal = TRUE,
        xlab = "Âge",
        las = 1,
        col = "orchid",
        main = "Distribution de l'âge des étudiants inscrits en première année"
)

```

Fig. 16. Code R de la création du boxplot de la population ageEtudiantV2




Fig. 17. Distribution de l'âge des étudiants inscrits en première année pour ageEtudiantV2

L'histogramme et la courbe de densité font apparaître un pic très marqué à gauche (autour de 19 ans) et deux bosses moins prononcées à droite.

```

hist(ageEtudiantV2,
     las = 1,
     ylim = c(0, 450),
     xlim = c(16, 24),
     col = "salmon",
     xlab = "Âge",
     cex.axis = 1.2,
     cex.main = 1.5,
     main = expression(italic("Distribution de l'âge des étudiants inscrits en première année")), col.main = "blue"
)

```

Fig. 18. Code R de la création de l'histogramme de la population ageEtudiantV2




Fig. 19. Distribution de l'âge des étudiants inscrits en première année pour ageEtudiantV2

```
plot(density(ageEtudiantV2), lwd = 2,
     col = "black")
```

Fig. 20. Code R de la création de l'histogramme lissé de la population ageEtudiantV2




Fig. 21. Histogramme lissé de la population ageEtudiantV2

Le test de Shapiro-Wilk donne une p-value de 0,384, largement supérieure au seuil de 5 %. On ne rejette donc pas l'hypothèse H_0 de normalité. Ce résultat peut paraître surprenant pour une distribution trimodale, mais s'explique par la proximité des trois modes (19, 22,5 et 25 ans) et leurs écarts-types relativement faibles, qui produisent une distribution globalement centrée difficile à distinguer d'une normale par ce test sur 1 400 observations. L'analyse graphique (histogramme, courbe de densité, QQ-plot) reste néanmoins plus informative pour identifier la structure multimodale.

```
> shapiro_test(ageEtudiantV2)
# A tibble: 1 × 3
  variable      statistic p.value
  <chr>         <dbl>   <dbl>
1 ageEtudiantV2 0.999 0.384
```

Fig. 22. Résultat du test de Shapiro-Wilk pour ageEtudiantV2

```
qqPlot(x = ageEtudiantV2)
```

Fig. 23. Code R de la création du QQ-plot de l'âge des étudiants inscrits en première année pour la population ageEtudiantV2




Fig. 24. QQ-plot de l'âge des étudiants inscrits en première année pour la population ageEtudiantV2

3 TP1 - Exercice 3 : Distribution de probabilité de l'estimateur

À travers ce troisième exercice, nous cherchons à étudier comment la taille d'un échantillon influence la qualité de l'estimateur de la moyenne. Nous utilisons l'estimateur classique de la moyenne empirique $\bar{x}_n$.

Nous commençons par créer la population de référence ageEtudiantV3 de taille 4 000, composée de trois modes : $N(19; 1)$ à 60 %, $N(25; 1,5)$ à 20 % et $N(35; 2,5)$ à 20 %. Cette population est ensuite assimilée à la population cible.

```
ageEtudiantV3 = generData3Mod(4000, 60, 20, 20, 19, 1, 25, 1.5, 35, 2.5)
```

Fig. 25. Code de la génération de la population ageEtudiantV3

```
hist(ageEtudiantV3,
     las = 1,
     ylim = c(0, 1000),
     xlim = c(20, 26),
     col = "pink",
     xlab = "Age",
     cex.axis = 1.2,
     cex.main = 1.5,
     main = expression(italic("Distribution de l'âge des étudiants inscrits en première année")), col.main = "blue"
)
```

Fig. 26. Code de la création de l'histogramme de ageEtudiantV3




Fig. 27. Distribution de l'âge des étudiants inscrits en première année pour ageEtudiantV3

```
plot(density(ageEtudiantV3), lwd = 2,
     col = "black", main = "Histogramme lissé")
```

Fig. 28. Code R de la création de l'histogramme lissé de la population ageEtudiantV3




Fig. 29. Histogramme lissé de la population ageEtudiantV3

La densité de probabilité de `ageEtudiantV3` présente une forme légèrement asymétrique avec un mode dominant à gauche (21 ans) et un mode secondaire vers 26 ans. Cette distribution fortement non-normale constitue un bon cas de test pour étudier le théorème central limite.

3.1 Fonction `estimeurMoy`

Nous créons la fonction `estimeurMoy` qui tire `nbEchant` échantillons aléatoires de taille `taille` depuis la base de données `db` et retourne le vecteur des moyennes calculées sur chaque échantillon. C'est ce vecteur qui approxime la distribution de l'estimateur $\bar{x}_n$.

```
estimeurMoy = function(db, nbEchant, taille){
  moyenne = replicate(nbEchant, mean(sample(db, taille)))
  return(moyenne)
}
```

Fig. 30. Code R de la création de la fonction `estimeurMoy`

3.2 Influence de la taille d'échantillon sur la distribution de l'estimateur

Nous appliquons la fonction `estimeurMoy` pour des tailles d'échantillon de 5, 10, 30, 50, 100 et 200, en créant à chaque fois 200 échantillons. Nous représentons ensuite la distribution de chaque estimateur à l'aide de courbes de densité, puis nous testons la normalité via le test de Shapiro-Wilk.

Taille $n = 5$. Pour un échantillon de taille 5, la distribution de l'estimateur est encore nettement asymétrique, à l'image de la population parente. Le pic de la courbe se situe proche de la moyenne globale de la population (21 ans), mais les queues sont larges et irrégulières. Le test de Shapiro-Wilk conduit au rejet de la normalité.

```
#La taille d'échantillon = 5
echantillon5 = estimeurMoy(ageEtudiantV3, 200, 5)

plot(density(echantillon5), lwd = 2,
     col = "black", main = "Distribution de probabilité l'estimateur = 5")

shapiro_test(echantillon5)
```

Fig. 31. Code R de la création de la fonction `estimeurMoy` pour un échantillon de taille 5




Fig. 32. Distribution de probabilité de l'estimateur pour $n = 5$

Taille $n = 10$. Avec 10 individus par échantillon, la distribution de l'estimateur commence à se concentrer autour de la vraie moyenne. On distingue encore une légère asymétrie, mais la forme se rapproche d'une courbe en cloche. La p-value du test de Shapiro-Wilk est encore inférieure à 0,05.

```
#La taille d'échantillon = 10
echantillon10 = estimeurMoy(ageEtudiantV3, 200, 10)

plot(density(echantillon10), lwd = 2,
     col = "black", main = "Distribution de probabilité l'estimateur = 10")

shapiro_test(echantillon10)
```

Fig. 33. Code R de la création de la fonction `estimeurMoy` pour un échantillon de taille 10




Fig. 34. Distribution de probabilité de l'estimateur pour $n = 10$

Taille $n = 30$. À partir de $n = 30$, la distribution de l'estimateur ressemble clairement à une loi normale, conformément au théorème central limite. La dispersion se réduit sensiblement par rapport aux tailles inférieures. Le test de Shapiro-Wilk ne rejette plus systématiquement la normalité.

```
#La taille d'échantillon = 30
echantillon30 = estimateurMoy(ageEtudiantV3, 200, 30)

plot(density(echantillon30), lwd = 2,
     col = "black", main = "Distribution de probabilité l'estimateur = 30")

shapiro_test(echantillon30)
```

Fig. 35. Code R de la création de la fonction estimateurMoy pour un échantillon de taille $n = 30$




Fig. 36. Distribution de probabilité de l'estimateur pour $n = 30$

Taille $n = 50, 100, 200$. Pour les tailles plus grandes, la convergence vers la normalité s'affirme et la variance de l'estimateur diminue progressivement : la distribution se resserre autour de la vraie moyenne. Les courbes de densité deviennent de plus en plus étroites et symétriques.

- Pour $n = 50$:

```
#La taille d'échantillon = 50
echantillon50 = estimateurMoy(ageEtudiantV3, 200, 50)

plot(density(echantillon50), lwd = 2,
     col = "black", main = "Distribution de probabilité l'estimateur = 50")

shapiro_test(echantillon50)
```

Fig. 37. Code R de la création de la fonction estimateurMoy pour un échantillon de taille $n = 50$




Fig. 38. Distribution de probabilité de l'estimateur pour $n = 50$

- Pour $n = 100$:

```
#La taille d'échantillon = 100
echantillon100 = estimateurMoy(ageEtudiantV3, 200, 100)

plot(density(echantillon100), lwd = 2,
     col = "black", main = "Distribution de probabilité l'estimateur = 100")

shapiro_test(echantillon100)
```

Fig. 39. Code R de la création de la fonction estimateurMoy pour un échantillon de taille $n = 100$




Fig. 40. Distribution de probabilité de l'estimateur pour $n = 100$

- Pour $n = 200$:

```
#La taille d'échantillon = 200
echantillon200 = estimateurMoy(ageEtudiantV3, 200, 200)

plot(density(echantillon200), lwd = 2,
     col = "black", main = "Distribution de probabilité l'estimateur = 200")

shapiro_test(echantillon200)
```

Fig. 41. Code R de la création de la fonction estimateurMoy pour un échantillon de taille $n = 200$




Fig. 42. Distribution de probabilité de l'estimateur pour n = 200

3.3 Superposition des densités et conclusion

Nous superposons l'ensemble des courbes de densité sur un même graphique pour visualiser directement l'effet de la taille d'échantillon.

```
plot(density(echantillon200), lwd = 2,
     col = "black", main = "Distribution de probabilité l'estimateur")
lines(density(echantillon10), lwd = 2,
      col = "orange")
lines(density(echantillon30), lwd = 2,
      col = "green")
lines(density(echantillon50), lwd = 2,
      col = "blue")
lines(density(echantillon100), lwd = 2,
      col = "purple")
lines(density(echantillon200), lwd = 2,
      col = "salmon")
```

Fig. 43. Code R de la superposition des densités




Fig. 44. Distribution de probabilité de l'estimateur

Ce graphique superposé illustre clairement le théorème central limite : quelle que soit la distribution de la population parente, la distribution de l'estimateur de la moyenne converge vers une loi normale au fur et à mesure que la taille d'échantillon augmente. De plus, la variance de l'estimateur décroît à mesure que n augmente, conformément à la formule théorique $\text{Var}(\bar{x}_n)$.

4 TP2 - Exercice 1 : Bootstrap de l'estimateur de la moyenne

Ce second TP introduit la méthode du bootstrap, une technique de ré-échantillonnage qui permet d'approcher la distribution d'un estimateur à partir d'un unique échantillon, sans hypothèse paramétrique sur la distribution sous-jacente.

Le principe fondamental consiste à considérer l'échantillon observé comme une approximation de la population, puis à simuler le tirage d'échantillons bootstrap par tirages aléatoires avec remise à partir de cet échantillon initial. L'estimateur d'intérêt est recalculé sur chaque échantillon bootstrap, et la distribution empirique de ces estimations approche la distribution réelle de l'estimateur.

4.1 Création de la population ageEtudiantV4

Nous créons la population ageEtudiantV4 de taille 500, comportant trois modes : 60 % des données issues de $N(20; 2)$, 20 % de $N(25; 1,4)$ et 20 % de $N(32; 1,6)$. Cette population représente notre échantillon initial de données.

```
ageEtudiantV4 = generData3Mod(500, 60, 20, 20, 2, 25, 1.4, 32, 1.6)
```

Fig. 45. Code R de la création de la population ageEtudiantV4

4.2 Fonction bootstrapEstimMoy

Nous créons la fonction bootstrapEstimMoy qui génère nbBoost échantillons bootstrap à partir de la base db. Chaque échantillon bootstrap est tiré avec remise et possède la même taille que l'échantillon initial. La fonction retourne le vecteur des moyennes calculées sur chacun de ces échantillons bootstrap.

```
bootstrapEstimMoy = function(db, nbBoost){  
  moyenne = replicate(nbBoost, mean(sample(db, length(db), replace=TRUE)))  
  return(moyenne)  
}
```

Fig. 46. Code R de la création de la fonction bootstrapMoy

La différence fondamentale avec la fonction estimateurMoy du TP1 réside dans le paramètre `replace = TRUE` : ici, le tirage se fait avec remise, ce qui est l'essence même de la méthode bootstrap. De plus, la taille de chaque échantillon bootstrap est égale à celle de l'échantillon initial (`length(db)`), contrairement au TP1 où la taille était un paramètre libre.

4.3 Simulation de 100 échantillons bootstrap

Nous utilisons bootstrapEstimMoy pour créer 100 échantillons bootstrap à partir de ageEtudiantV4. La fonction `summary` nous permet d'obtenir les statistiques descriptives de la distribution bootstrap de l'estimateur.

```
echantillon100 = bootstrapEstimMoy(ageEtudiantV4, 100)  
  
summary(echantillon100)
```

Fig. 47. Code R de la création de 100 échantillons bootstrap

```
> summary(echantillon100)  
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.   
 23.30   23.38   23.42   23.42   23.46   23.58
```

Fig. 48. Code R du résultat de la fonction `summary()`

Les 100 moyennes bootstrap sont distribuées autour de la moyenne empirique de ageEtudiantV4. L'étendue de cette distribution donne une première indication de la variabilité de l'estimateur.

4.4 Représentation graphique de la distribution bootstrap

Nous représentons la distribution de l'estimateur bootstrap à l'aide d'une courbe de densité (Fig. 50). Cette courbe illustre la distribution de probabilité approchée de la moyenne $\bar{x}_n$, simulée par le bootstrap.

```
plot(density(echantillon100), lwd = 2,  
     col = "black", main = "Distribution de l'estimateur")
```

Fig. 49. Code R de la création de l'estimateur de densité




Fig. 50. Distribution de l'estimateur

La courbe de densité obtenue présente une forme approximativement gaussienne, centrée autour de la vraie moyenne de ageEtudiantV4. Ceci est cohérent avec le théorème central limite : même si la population parente n'est pas normale (elle est trimodale), l'estimateur de la moyenne sur des échantillons de grande taille suit approximativement une loi normale.

4.5 Intervalle de confiance bootstrap au niveau 95 %

Nous calculons l'intervalle de confiance bootstrap au niveau de confiance 95 % en utilisant la méthode des percentiles. Les bornes s_1 et s_2 de l'intervalle correspondent respectivement aux seuil 2,5 % et 97,5 % percentiles de la distribution bootstrap des estimations.

```
quantile(echantillon100, probs=c(0.025, 0.975))
```

Fig. 51. Code R des quantiles de l'échantillon100

```
> quantile(echantillon100, probs=c(0.025, 0.975))  
      2.5%      97.5%  
23.33181 23.52116
```

Fig. 52. Quantiles de l'échantillon100

L'intervalle de confiance bootstrap à 95 % obtenu est de la forme $IC(0,95) = [s_1 ; s_2]$, où s_1 est la $B \times 0,025$ valeur de la liste triée des moyennes bootstrap, et s_2 la $B \times 0,975$ valeur. Cet intervalle permet de quantifier l'incertitude sur l'estimation de la moyenne de l'âge des étudiants.

La méthode bootstrap des percentiles présente l'avantage de ne faire aucune hypothèse paramétrique sur la forme de la distribution de l'estimateur. Elle est particulièrement bien adaptée aux situations, comme la nôtre, où la distribution de la population n'est pas normale.

Conclusion

À travers ces deux travaux pratiques, nous avons exploré les principales techniques d'estimation par sondage simple dans le cadre de la statistique inférentielle.

Dans le cadre du premier TP, nous avons d'abord appris à simuler des populations multimodales en superposant des distributions normales via les fonctions `generData2Mod` et `generData3Mod`. L'analyse descriptive et graphique (boxplot, histogramme, courbe de densité, QQ-plot) a mis en évidence le caractère multimodal de ces distributions. Le test de Shapiro-Wilk n'a cependant pas permis de rejeter formellement l'hypothèse de normalité pour les populations `ageEtudiantV1` ($p = 0,0707$) et `ageEtudiantV2` ($p = 0,384$), ce qui illustre les limites de ce test face à des distributions dont les modes sont proches : l'analyse graphique reste dans ce cas plus informative. Enfin, l'étude de la distribution de l'estimateur de la moyenne pour différentes tailles d'échantillon a mis en lumière le théorème central limite : la distribution de l'estimateur converge vers une loi normale à mesure que n augmente, et la variance de l'estimateur décroît proportionnellement à $1/n$.

Dans le cadre du second TP, nous avons mis en œuvre la méthode du bootstrap. Contrairement à l'approche du TP1 qui supposait un accès à la population entière, le bootstrap repose sur un unique échantillon de données, ce qui le rend plus réaliste en pratique. La fonction `bootstrapEstimMoy` permet de simuler la distribution de l'estimateur par ré-échantillonnage avec remise. L'intervalle de confiance bootstrap à 95 % calculé par la méthode des percentiles constitue une estimation robuste et non paramétrique de l'incertitude sur la moyenne.

Ces deux approches sont complémentaires : la première illustre les propriétés théoriques de l'estimateur sous des conditions contrôlées, tandis que la seconde offre un outil pratique applicable à des données réelles sans supposer de forme particulière pour la distribution sous-jacente.

Table des figures

1	Code R de la population générée	4
2	Code R de la création de la fonction generData2Mod	4
3	Code R de la génération de la population ageEtudiant	4
4	Code R de la création de la fonction generData3Mod	4
5	Code R du résultat de la fonction summary()	5
6	Code R de la création du boxplot	5
7	Distribution de l'âge des étudiants inscrits en première année pour ageEtudiantV1	5
8	Code R de la création de l'histogramme	6
9	Distribution de l'âge des étudiants inscrits en première année pour ageEtudiantV1	6
10	Code R de la création de l'histogramme lissé	6
11	Histogramme lissé	6
12	Code R de la création du QQ-plot de l'âge des étudiants inscrits en première année	7
13	QQ-plot de l'âge des étudiants inscrits en première année	7
14	QQ-plot de l'âge des étudiants inscrits en première année	7
15	Code R du résultat de la fonction summary()	7
16	Code R de la création du boxplot de la population ageEtudiantV2	8
17	Distribution de l'âge des étudiants inscrits en première année pour ageEtudiantV2	8
18	Code R de la création de l'histogramme de la population ageEtudiantV2	8
19	Distribution de l'âge des étudiants inscrits en première année pour ageEtudiantV2	8
20	Code R de la création de l'histogramme lissé de la population ageEtudiantV2	9
21	Histogramme lissé de la population ageEtudiantV2	9
22	Résultat du test de Shapiro-Wilk pour ageEtudiantV2	9
23	Code R de la création du QQ-plot de l'âge des étudiants inscrits en première année pour la population ageEtudiantV2	9
24	QQ-plot de l'âge des étudiants inscrits en première année pour la population ageEtudiantV2	9
25	Code de la génération de la population ageEtudiantV3	10
26	Code de la création de l'histogramme de ageEtudiantV3	10
27	Distribution de l'âge des étudiants inscrits en première année pour ageEtudiantV3	10
28	Code R de la création de l'histogramme lissé de la population ageEtudiantV3	10
29	Histogramme lissé de la population ageEtudiantV3	10
30	Code R de la création de la fonction estimateurMoy	11
31	Code R de la création de la fonction estimateurMoy pour un échantillon de taille 5	11
32	Distribution de probabilité de l'estimateur pour n = 5	11
33	Code R de la création de la fonction estimateurMoy pour un échantillon de taille 10	11
34	Distribution de probabilité de l'estimateur pour n = 10	12
35	Code R de la création de la fonction estimateurMoy pour un échantillon de taille n = 30	12
36	Distribution de probabilité de l'estimateur pour n = 30	12
37	Code R de la création de la fonction estimateurMoy pour un échantillon de taille n = 50	12
38	Distribution de probabilité de l'estimateur pour n = 50	13
39	Code R de la création de la fonction estimateurMoy pour un échantillon de taille n = 100	13
40	Distribution de probabilité de l'estimateur pour n = 100	13
41	Code R de la création de la fonction estimateurMoy pour un échantillon de taille n = 200	13
42	Distribution de probabilité de l'estimateur pour n = 200	14
43	Code R de la superposition des densités	14
44	Distribution de probabilité de l'estimateur	14
45	Code R de la création de la population ageEtudiantV4	15
46	Code R de la création de la fonction bootstrapMoy	15
47	Code R de la création de 100 échantillons bootstrap	15
48	Code R du résultat de la fonction summary()	15
49	Code R de la création de l'estimateur de densité	16
50	Distribution de l'estimateur	16
51	Code R des quantiles de l'echantillon100	16
52	Quantiles de l'echantillon100	16