

IUT Grand Ouest Normandie

Bachelor Universitaire de Technologie
Science des Données
Campus de Lisieux

Science des Données 1 - SAE 1.03
Préparation et synthèse d'un tableau de données

Thématique

Analyse exploratoire du carnet de commande d'une
entreprise de vente par correspondance



Auteurs

Selma Bennani
Thalya-Eva Kerraud
Charlotte Lefauquer
Nadira Aura Maulidia

Table des matières

Introduction	3
1 Analyse descriptive des données	4
1.1 Classement des segments par nombre de transactions	4
1.2 Classement des catégories de produits selon le chiffre d'affaire	4
1.3 Classement des sous-catégories de fournitures de bureau par rentabilité	5
1.4 Distribution du montant des profits d'une transaction	5
2 Etude des relations entre les variables observées	6
2.1 Répartition du volume de transactions par sous-catégorie	6
2.2 Répartition des bénéfices selon les États	6
2.3 Top 10 des États les plus rentables par catégories	7
2.4 Distribution des profits par transaction selon les États	8
2.5 Distribution du volume de transaction par type de client	8
2.6 Évolution du bénéfice d'une transaction selon le prix de vente	9
2.7 Association entre les sous-catégorie et les bénéfices par transactions	9
2.8 Les transaction a profit négatif par sous-catégorie	10
Conclusion	11
Table des figures	12

Introduction

Dans le cadre de l'analyse du carnet de commandes de l'entreprise Superstore, spécialisée dans la vente par correspondance de mobilier, de fournitures de bureau et de produits technologiques, nous avons réalisé une étude exploratoire approfondie à partir des données de ventes enregistrées entre 2019 et 2022.

Ce jeu de données contient en particulier les informations suivantes (cf. Fig. 1) :

- La date de commande
- La date d'expédition
- Le type de client
- L'état et la ville de destination
- Le prix de vente à l'unité
- La quantité
- La remise
- Le profit

L'objectif de ce rapport est d'apporter un éclairage précis et opérationnel sur les performances commerciales de l'entreprise. À travers une série de visualisations construites sous R, nous analysons les dynamiques de vente, identifions les segments les plus porteurs, évaluons la rentabilité des différentes catégories et sous-catégories de produits, et mettons en évidence les disparités géographiques influençant les résultats. Cette analyse vise à fournir au service commercial des éléments factuels permettant d'orienter les décisions stratégiques, qu'il s'agisse d'optimiser l'offre, d'ajuster les politiques tarifaires ou de cibler plus efficacement les segments de clientèle.

Order ID	Order Date	Ship Date	Ship Mode	Customer ID	Customer Name	Segment	Country	City	State	Postal Code	Region	Product ID	Category	Sub-Category	
1	CA-2019-103800	2019-01-03	2019-01-07	Standard Class	DP-13000	Darren Powers	Consumer	United States	Houston	Texas	77095	Central	OFF-PA-10000174	Office Supplies	Paper
2	CA-2019-112326	2019-01-04	2019-01-08	Standard Class	PO-19195	Phyllina Ober	Home Office	United States	Naperville	Illinois	60540	Central	OFF-LA-10003223	Office Supplies	Labels
3	CA-2019-112326	2019-01-04	2019-01-08	Standard Class	PO-19195	Phyllina Ober	Home Office	United States	Naperville	Illinois	60540	Central	OFF-ST-10002743	Office Supplies	Storage
4	CA-2019-112326	2019-01-04	2019-01-08	Standard Class	PO-19195	Phyllina Ober	Home Office	United States	Naperville	Illinois	60540	Central	OFF-BI-10004094	Office Supplies	Binders
5	CA-2019-141817	2019-01-05	2019-01-12	Standard Class	MB-18085	Mick Brown	Consumer	United States	Philadelphia	Pennsylvania	19143	East	OFF-AR-10003478	Office Supplies	Art
6	CA-2019-167199	2019-01-06	2019-01-10	Standard Class	ME-17320	Maria Etezadi	Home Office	United States	Henderson	Kentucky	42420	South	OFF-AR-10001662	Office Supplies	Art
7	CA-2019-167199	2019-01-06	2019-01-10	Standard Class	ME-17320	Maria Etezadi	Home Office	United States	Henderson	Kentucky	42420	South	FUR-CH-10004063	Furniture	Chairs
8	CA-2019-167199	2019-01-06	2019-01-10	Standard Class	ME-17320	Maria Etezadi	Home Office	United States	Henderson	Kentucky	42420	South	OFF-BI-10004632	Office Supplies	Binders
9	CA-2019-106054	2019-01-06	2019-01-07	First Class	JO-15145	Jack O'Brian	Corporate	United States	Athens	Georgia	30605	South	OFF-PA-10002399	Office Supplies	Art
10	CA-2019-167199	2019-01-06	2019-01-10	Standard Class	ME-17320	Maria Etezadi	Home Office	United States	Henderson	Kentucky	42420	South	TEC-PH-10004977	Technology	Phones
11	CA-2019-167199	2019-01-06	2019-01-10	Standard Class	ME-17320	Maria Etezadi	Home Office	United States	Henderson	Kentucky	42420	South	TEC-PH-10004539	Technology	Phones
12	CA-2019-167199	2019-01-06	2019-01-10	Standard Class	ME-17320	Maria Etezadi	Home Office	United States	Henderson	Kentucky	42420	South	OFF-FA-10001883	Office Supplies	Fasteners
13	CA-2019-167199	2019-01-06	2019-01-10	Standard Class	ME-17320	Maria Etezadi	Home Office	United States	Henderson	Kentucky	42420	South	OFF-PA-10000955	Office Supplies	Paper
14	CA-2019-130813	2019-01-06	2019-01-08	Second Class	LS-17230	Lyccoris Saunders	Consumer	United States	Los Angeles	California	90049	West	OFF-PA-10002005	Office Supplies	Paper
15	CA-2019-105417	2019-01-07	2019-01-12	Standard Class	VS-21820	Vivek Sundaresam	Consumer	United States	Huntsville	Texas	77340	Central	FUR-FU-10004864	Furniture	Furnishings
16	CA-2019-105417	2019-01-07	2019-01-12	Standard Class	VS-21820	Vivek Sundaresam	Consumer	United States	Huntsville	Texas	77340	Central	OFF-BI-10003708	Office Supplies	Binders
17	CA-2019-135405	2019-01-09	2019-01-13	Standard Class	MS-17830	Melanie Seite	Consumer	United States	Laredo	Texas	78041	Central	OFF-AR-10004078	Office Supplies	Art
18	CA-2019-135405	2019-01-09	2019-01-13	Standard Class	MS-17830	Melanie Seite	Consumer	United States	Laredo	Texas	78041	Central	TEC-AC-10001266	Technology	Accessories
19	CA-2019-149020	2019-01-10	2019-01-15	Standard Class	AJ-10780	Anthony Jacobs	Corporate	United States	Springfield	Virginia	22153	South	FUR-FU-10000965	Furniture	Furnishings
20	CA-2019-149020	2019-01-10	2019-01-15	Standard Class	AJ-10780	Anthony Jacobs	Corporate	United States	Springfield	Virginia	22153	South	OFF-LA-10004272	Office Supplies	Labels
21	CA-2019-130092	2019-01-11	2019-01-14	First Class	SV-20365	Seth Vernon	Consumer	United States	Dover	Delaware	19901	East	FUR-FU-10000010	Furniture	Furnishings
22	CA-2019-162775	2019-01-13	2019-01-15	Second Class	CS-12250	Chris Selesnick	Corporate	United States	Bossier City	Louisiana	71111	South	OFF-ST-10000025	Office Supplies	Storage
23	CA-2019-162775	2019-01-13	2019-01-15	Second Class	CS-12250	Chris Selesnick	Corporate	United States	Bossier City	Louisiana	71111	South	OFF-BI-10004187	Office Supplies	Binders
24	CA-2019-157147	2019-01-13	2019-01-18	Standard Class	BD-11605	Brian Dahlen	Consumer	United States	San Francisco	California	94109	West	OFF-AR-10003514	Office Supplies	Art
25	CA-2019-118192	2019-01-13	2019-01-18	Standard Class	MM-17920	Michael Moore	Consumer	United States	Newark	Ohio	43055	East	OFF-BI-10003476	Office Supplies	Binders

Fig. 1. Extrait des données concernant les commandes d'entreprise Superstore

Dans la suite, nous proposons de réaliser une analyse exploratoire de ces données sur l'ensemble de la période d'étude. Cette analyse est structurée en deux grandes parties : une première partie consacrée à l'analyse descriptive des données, et une seconde partie dédiée à l'étude des relations entre les variables observées.

1 Analyse descriptive des données

Cette première analyse vise à identifier quels segments de clientèle génèrent le plus grand nombre de transactions. Cette information permet de déterminer quels types de clients constituent le cœur de l'activité commerciale de Superstore..

1.1 Classement des segments par nombre de transactions

L'analyse (cf. Fig. 2) montre que le segment "Consumer" (Grand Public) domine largement l'activité avec le plus grand volume de transactions sur la période 2019-2022. Il est suivi par le segment "Corporate" (Entreprises), tandis que le segment "Home Office" (Télétravail) enregistre l'activité la plus faible. Cette répartition indique que la clientèle individuelle est le moteur principal de Superstore. Une stratégie visant à dynamiser le segment "Home Office" pourrait constituer un levier de croissance futur.




Fig. 2. Type de clients

1.2 Classement des catégories de produits selon le chiffre d'affaire

On peut observer (cf. Fig. 3) que les écarts entre les différentes catégories de produits sont relativement faibles. La catégorie générant le chiffre d'affaires le plus élevé est celle des technologies, avec un peu plus de 836 000 dollars. Elle est suivie par celle de meuble qui atteint précisément 742 000 dollars, puis par les fournitures de bureau avec près de 720 000 dollars.




Fig. 3. Catégories de produits

1.3 Classement des sous-catégories de fournitures de bureau par rentabilité

On peut déterminer grâce à ce graphique (cf. Fig. 4) que le classement de chaque sous-catégories de produit de la famille des fournitures de bureau selon les bénéfices, en première position on a la sous-catégories "*Paper*" avec un bénéfice supérieur à 30000, ensuite en deuxième position on a la sous-catégories "*Binders*" avec un bénéfice d'environ 30000. En troisième place on a la sous-catégories "*Storage*" avec un bénéfice supérieur a 20000. "*Appliance*" est en quatrième position avec un bénéfice supérieur a 15000, suivit de la sous-catégorie "*Labels*" en cinquième position avec un bénéfice qui est supérieur a 5000, "*Fasteners*" est en sixième place avec un bénéfice en dessous de 500 mais toujours supérieur a 0. Enfin, la sous-catégorie "*Supplies*" présente un bénéfice négatif, indiquant une légère perte, toutefois négligeable à l'échelle globale de l'entreprise.




Fig. 4. Sous-catégories de fournitures de bureau

1.4 Distribution du montant des profits d'une transaction

On peut noter (cf. Fig. 6) que la distribution des profits présente une forte hétérogénéité. Le premier quartile très faible, associé à une médiane relativement modeste, montre que la majorité des transactions génèrent un profit. En revanche, le troisième quartile nettement plus élevé indique qu'une partie non négligeable des transactions est beaucoup plus rentable. La médiane étant légèrement supérieure à zéro, cela indique que 50% des transactions génèrent un profit positif. On peut observer (cf. Fig. 5) également la présence de points atypiques, aussi bien négatifs que positifs, ce qui suggère une forte variabilité des profits. La distribution présente une asymétrie vers la droite, traduisant la présence de quelques transactions très profitables qui tirent la moyenne vers le haut.




Fig. 5. Distribution des profits par transaction

Profit Moyen	1er Quartile	Médiane	3e Quartile
28.68876	1.7248	8.6730	29.3680

Fig. 6. Profit moyen et quartiles

2 Etude des relations entre les variables observées

Nous évaluons ici la contribution des différentes catégories de produits au chiffre d'affaires global. Cette analyse met en lumière les familles de produits les plus stratégiques pour l'entreprise.

2.1 Répartition du volume de transactions par sous-catégorie

On peut observer (cf. Fig. 7) que le volume de transactions est principalement porté par la catégorie Office Supplies, dont les sous-catégories comme *Binders* et *Paper* enregistrent les fréquences d'achat les plus élevées. À l'inverse, les catégories *Furniture* et *Technology* présentent des volumes plus réduits, concentrés sur des articles comme les *Furnishings* ou les *Phones*. Cette répartition montre que le flux logistique du magasin dépend majoritairement de produits consommables à faible valeur unitaire, tandis que les produits plus complexes et coûteux, tels que les *Copiers* ou les *Tables*, génèrent logiquement un nombre de transactions bien plus limité.




Fig. 7. Répartition du volume de transactions par sous-catégorie

2.2 Répartition des bénéfices selon les États

Le graphique (cf. Fig. 8) met en évidence une forte disparité de rentabilité entre les États et les catégories de produits. On observe que les bénéfices sont portés par des pôles majeurs comme l'Indiana, Washington et Michigan, où la catégorie *Technology* (en bleu) génère les profits les plus élevés. À l'opposé, des États comme l'Ohio et le Texas affichent des pertes nettes importantes, particulièrement sur les segments *Technology* et *Office Supplies*.




Fig. 8. Répartition des bénéfices selon les États

Cette hétérogénéité confirme une association entre la localisation géographique et la performance financière : un même produit peut être très rentable dans un État et déficitaire dans un autre. Cette dépendance, justifiée par le calcul du rapport de corrélation (cf. Fig. 11), démontre que des facteurs locaux (taxes, remises ou frais logistiques) influencent directement ($\eta^2 = 0.0324$) la structure des profits de l'entreprise.

Facteur	η^2
États	0.0324

Fig. 9. La rapport de corrélation

2.3 Top 10 des États les plus rentables par catégories

L'étude des bénéfices (cf. Fig. 10) montre une forte disparité géographique, avec une concentration des profits dans des États piliers comme la California et New York, alors que d'autres zones comme le Texas affichent des pertes marquées. Cette hétérogénéité est confirmée par le calcul du rapport de corrélation (cf. Fig. 11), qui justifie statistiquement ($\eta^2 = 0.0324$) l'existence d'une association entre la localisation géographique et la rentabilité des ventes. On en conclut que l'État d'implantation est un facteur déterminant de la performance financière globale de l'entreprise.




Fig. 10. Répartition des sous-catégories selon les catégories

Facteur	η^2
États	0.0324

Fig. 11. La rapport de corrélation

2.4 Distribution des profits par transaction selon les États

On peut observer (cf. Fig. 12) que les distributions des bénéfices varient légèrement selon les États, cependant, les distributions restent globalement proches les unes des autres. Cela suggère une association visuelle faible (cf. Fig. 13) entre l'État et le bénéfice marquer par rapport de corrélation ($\eta^2 = 0.041$) ce qui signifie que l'association entre la variable bénéfice (profit) et état (state) est une association très faible.




Fig. 12. Distribution des profits par transaction selon les États

Facteur	P-value	η^2
Segment	2e-16	0.041

Fig. 13. La rapport de corrélation

2.5 Distribution du volume de transaction par type de client

Concernant la distribution du volume de transaction, on peut observer (cf. Fig. 14) qu'il est évident qu'il n'existe pas d'association significative entre le type de client et le volume de transaction (cf. Fig. 15). De plus, on trouve que la rapport de corrélation indique une association très faible ($\eta^2 = 7.38e-05$), ce qui confirme que le facteur "type de client" n'a qu'un impact significatif sur le volume de transaction.

La distribution du volume de transaction par type de client




Fig. 14. Volume de transaction

Facteur	P-value	η^2
Segment	0.692	7.375821e-05

Fig. 15. La rapport de corrélation

2.6 Évolution du bénéfice d'une transaction selon le prix de vente

L'analyse (cf. Fig. 16) montre une corrélation positive modérée entre le montant des ventes et le bénéfice réalisé. Si les transactions les plus importantes génèrent souvent les profits les plus élevés, on observe également que les pertes les plus lourdes surviennent sur des produits à prix de vente élevé. Le coefficient de corrélation confirme cette association. On en conclut que l'augmentation du prix de vente n'est pas une garantie systématique de profit plus élevé, en raison probablement de l'impact des remises accordées sur les grosses transactions.




Fig. 16. Volume de transaction

2.7 Association entre les sous-catégorie et les bénéfices par transactions

Le graphique (cf. Fig. 17) met en évidence une forte hétérogénéité de performance entre les types de produits. Les catégories les plus performantes, notamment les *Copiers*, se distinguent par des bénéfices élevés et relativement stables. À l'inverse, certaines catégories apparaissent plus critiques : les *Tables* et les *Supplies* présentent une médiane de profit proche de zéro, voire négative, ce qui indique qu'une part importante de ces transactions est réalisée à perte. Enfin, l'indicateur statistique (R^2) confirme que la sous-catégorie constitue un facteur explicatif majeur de la rentabilité d'une transaction.




Fig. 17. Répartition des bénéfices par sous-catégorie

2.8 Les transaction a profit négatif par sous-catégorie

On peut noter clairement en évidence (cf. Fig. ??) que certaines sous-catégories concentrent l'essentiel des pertes, notamment "*Binders*" avec respectivement en peu plus de 600 transactions, qui constitue la principale source de pertes, tandis que d'autres, comme "*Fasteners*" qui contribuent très faiblement au volume total avec seulement 12 transactions. Cette représentation permet ainsi de cibler rapidement les segments nécessitant une attention prioritaire.

Répartition des transaction a profit négatif par sous-catégorie




Fig. 18. Répartition des transaction a profit négatif par sous-catégorie

Conclusion

L'analyse exploratoire menée sur les données de Superstore entre 2019 et 2022 met en évidence plusieurs enseignements clés pour la stratégie commerciale de l'entreprise. Le segment Consumer constitue le principal moteur d'activité, tandis que certaines sous-catégories notamment *Paper*, *Binders* ou *Copiers* se distinguent par leur forte contribution aux bénéfices. À l'inverse, des produits tels que *Tables* ou *Supplies* présentent une rentabilité plus faible, voire négative, ce qui suggère la nécessité d'un réajustement de l'offre ou des conditions commerciales.

L'étude révèle également une hétérogénéité marquée entre les États : certains territoires génèrent des profits significatifs, tandis que d'autres enregistrent des pertes, en particulier sur les catégories *Technology* et *Office Supplies*. Bien que l'association statistique entre l'État et le profit soit faible, ces disparités soulignent l'importance de prendre en compte les spécificités locales : coûts logistiques, remises, structure de la demande dans la définition des priorités commerciales.

Enfin, l'analyse des relations entre variables montre que le prix de vente n'est pas un indicateur suffisant pour prédire la rentabilité, notamment en raison de l'impact des remises sur les transactions à forte valeur. L'ensemble de ces résultats offre une vision claire des leviers de performance et des zones de vigilance, permettant au service commercial d'orienter ses actions de manière plus ciblée et plus efficace.

Table des figures

1	Extrait des données concernant les commandes d'entreprise Superstore	3
2	Type de clients	4
3	Catégories de produits	4
4	Sous-catégories de fournitures de bureau	5
5	Distribution des profits par transaction	5
6	Profit moyen et quartiles	5
7	Répartition du volume de transactions par sous-catégorie	6
8	Répartition des bénéfices selon les États	6
9	La rapport de corrélation	7
10	Répartition des sous-catégories selon les catégories	7
11	La rapport de corrélation	7
12	Distribution des profits par transaction selon les États	8
13	La rapport de corrélation	8
14	Volume de transaction	8
15	La rapport de corrélation	8
16	Volume de transaction	9
17	Répartition des bénéfices par sous-catégorie	9
18	Répartition des transaction a profit négatif par sous-catégorie	10